DOCUMENTAÇÃO TÉCNICA

Script_Final.R

Persistência e Eficiência no Mercado Brasileiro de Infraestrutura

TCC — Universidade Federal de Santa Catarina (UFSC)

Autor	Marcos Rafael Hoffmann
Versão	6.0
Data	Dezembro / 2025
Linguagem	R >= 4.2.0
Saída	Resultadosr.xlsx

Sumário

Sumário 2
1. Visão Geral 3
1.1 Pipeline Geral 3
2. Dependências e Requisitos 4
2.1 Requisitos de Sistema 4
2.2 Pacotes R 4
2.3 Arquivos Locais Necessários 5
3. Estrutura Detalhada do Código 6
3.0 Setup e Semente Aleatória 6
3.1 Coleta de Dados 6
3.2 Filtros de Liquidez 6
3.3 Construção do Índice IIA-INFRA 7
3.4 Alinhamento de Calendário 7
3.5 Estatísticas Descritivas (Tabela 4) 7
3.6 Testes de Raiz Unitária (Tabela 5) 7
3.7 Teste KPSS de Estacionariedade (Tabela 6) 8
3.8 Quebras Estruturais — Bai e Perron (Tabela 7) 8
3.9 Estimação de Memória Longa — GSEM / Robinson 1995 (Tabela 8) 8
3.10 Modelos ARMA(1,1)-FIGARCH(1,d,1) (Tabelas 9, 9B e 10) 9
3.11 Correlações de Pearson (Tabela 11) 9
3.12 Backtesting de VaR (Tabela 12) 9
3.13 Exportação para Excel 10
4. Decisões Metodológicas Relevantes 11
4.1 Ausência de Ajuste de Calendário 11
4.2 LOCF para Dados de Preço 11
4.3 Dummies de Quebra Estrutural na Equação de Média 11
4.4 Backtesting sobre Retornos Empíricos 11
4.5 Fallback sGARCH 11
5. Fluxo de Execução e Saídas 12
5.1 Ordem de Execução 12
5.2 Arquivo de Saída 12
6. Tratamento de Erros e Robustez 13
7. Referências Metodológicas 14

1. Visão Geral

Este script implementa integralmente o pipeline de análise quantitativa do TCC de Marcos Rafael Hoffmann, desenvolvido na UFSC. O objetivo central é investigar a persistência de volatilidade e a eficiência informacional do mercado brasileiro de Fundos de Investimento em Infraestrutura (FI-Infra), por meio de técnicas econométricas de ponta aplicadas a dados de alta frequência (diários).

O pipeline cobre desde a coleta automatizada de dados até a exportação de resultados para Excel, passando por filtros de liquidez, construção de índice proprietário, testes de memória longa, modelagem GARCH fracionária e backtesting de VaR.

1.1 Pipeline Geral

Etapa	Módulo	Descrição Resumida
1	Coleta de Dados	Yahoo Finance + arquivos locais B3/ANBIMA
2	Filtros de Liquidez	Seleção de ativos por ADTV, frequência e N de observações
3	Índice IIA-INFRA	Construção do índice ponderado por ADTV com cap de 15%
4	Alinhamento de Calendário	Left join no calendário IBOV; NAs substituídos por 0
5	Estatísticas Descritivas	Média, desvio, assimetria, curtose, Jarque-Bera
6	Raiz Unitária	ADF (BIC) e Phillips-Perron — 3 especificações cada
7	Estacionariedade KPSS	Especificações mu e tau
8	Quebras Estruturais	Bai e Perron (2003) — até 5 quebras, h = 15%
9	Memória Longa	GSEM — Robinson (1995) em 3 bandas de frequências
10	Modelos GARCH	ARMA(1,1)-FIGARCH(1,d,1) com erros t-Student
11	Correlações	Pearson sobre resíduos padronizados
12	Backtesting VaR	Kupiec (1995) e Christoffersen (1998) — 95% e 99%
13	Exportação	writexl para Resultados_V6_MASTER.xlsx

2. Dependências e Requisitos

2.1 Requisitos de Sistema

Requisito	Versão Mínima	Observação
R	>= 4.2.0	Necessário para compatibilidade com todos os pacotes
Sistema Operacional	Windows / Linux / macOS	Sem restrição de plataforma
Acesso à Internet	Obrigatório	Para coleta via quantmod

2.2 Pacotes R

Pacote	Finalidade	Instalação Automática
quantmod	Download de séries financeiras	Sim
dplyr / tidyr	Manipulação e transformação de data frames	Sim
lubridate	Parsing e operações com datas	Sim
zoo	Séries temporais irregulares; LOCF	Sim
tseries	Testes estatísticos de séries temporais	Sim
urca	Testes ADF, Phillips-Perron e KPSS	Sim
strucchange	Detecção de quebras estruturais (Bai-Perron)	Sim
fracdiff	Modelos de diferenciação fracionária	Sim
rugarch	Estimação de modelos GARCH/FIGARCH	Sim
FinTS	Teste ARCH-LM para efeitos ARCH nos resíduos	Sim
ggplot2	Visualizações gráficas	Sim
knitr	Formatação de tabelas no console	Sim
readxl	Leitura de arquivos .xlsx e .xls	Sim
moments	Cálculo de assimetria e curtose	Sim
writexl	Exportação de resultados para Excel	Sim

Todos os pacotes são instalados automaticamente caso não estejam presentes, por meio do bloco de setup na seção 0 do script.

2.3 Arquivos Locais Necessários

Arquivo	Fonte	Colunas Esperadas
IFIX.csv	B3 (exportação manual)	Col 1: Data (dd/mm/aaaa), Col 2: Valor (vírgula decimal)
IDA_IPCA.xlsx	ANBIMA	Col 2: Data, Col 3: Nível do índice
IDA_IPCA_ex_Infra.xlsx	ANBIMA	Col 2: Data, Col 3: Número-índice

Esses arquivos devem estar no diretório de trabalho do R no momento da execução. Os arquivos usados para execução da pesquisa estão disponíveis do repositório https://github.com/themrhoffmann/MemoriaLonga

3. Estrutura Detalhada do Código

3.0 Setup e Semente Aleatória

O bloco inicial define o vetor de pacotes necessários, verifica sua disponibilidade via requireNamespace() e os carrega em lote com lapply(). A semente aleatória é fixada em 42 (set.seed(42)) para garantir reprodutibilidade total dos resultados.

Função auxiliar `print_table()`: formata e imprime qualquer data frame no console com separadores visuais, título e número de casas decimais configurável. Utilizada em todos os módulos de resultados.

3.1 Coleta de Dados

Universo de ativos: **36 FI-Infra listados na B3**, identificados pelos sufixos .SA O período de análise vai de `2019-01-01` a `2025-12-31`.

Mecanismo de coleta: loop com tryCatch() para cada ticker, armazenando o xts retornado por getSymbols() em uma lista nomeada. Erros de conexão ou ativos sem dados são registrados no console sem interromper a execução.

Além dos FI-Infra, são coletados ou lidos quatro benchmarks:

- IBOV — via quantmod, convertido para retornos log diários
- IFIX — CSV local da B3, com parsing de data no formato dd/mm/aaaa e conversão de vírgula decimal
- IDA-IPCA — XLSX da ANBIMA, retorno log calculado sobre o número-índice
- IDA-IPCA ex-Infra — XLSX da ANBIMA, mesma estrutura do IDA-IPCA

3.2 Filtros de Liquidez

Três funções auxiliares são definidas e aplicadas via sapply() sobre todos os tickers coletados:

Função	Métrica	Critério de Corte
calc_adtv()	Volume Médio Diário Negociado (ADTV = preço ajustado × volume)	≥ R$ 50.000
calc_freq()	Frequência de negociação (% de dias com preço ajustado > 0)	≥ 60%
calc_nobs()	Número de observações válidas (preço ajustado não nulo)	≥ 250 dias

O resultado é a tabela liquidity_metrics, da qual se deriva o vetor selected_tickers contendo apenas os ativos que passam em todos os três filtros simultaneamente. Esta seleção é apresentada como Tabela 2 no console.

3.3 Construção do Índice IIA-INFRA

O índice proprietário IIA-INFRA (Índice de Infraestrutura ANBIMA) é construído em três etapas:

- Fusão de preços ajustados: os xts individuais são mesclados por data via do.call(merge, ...) e tratados com LOCF (na.locf()) para preencher dias sem negociação, preservando a microestrutura de mercado.
- Cálculo de retornos log: diff(log(prices_locf))[-1,] produz retornos log diários.
- Ponderação por ADTV com cap de 15%: os pesos são proporcionais ao ADTV de cada ativo selecionado. Um loop iterativo de até 20 ciclos redistribui o excesso dos ativos que ultrapassam o teto de 15% proporcionalmente aos demais.

O retorno diário do índice é calculado com renormalização por dia: para cada data, os pesos dos ativos com dado disponível são recalibrados para somar 1, evitando viés de ausências pontuais.

3.4 Alinhamento de Calendário

O calendário de referência é o do IBOV (dias úteis da B3). Todas as séries são alinhadas por left_join na coluna Date. Valores ausentes após o join (dias em que o benchmark foi negociado mas a série específica não) são substituídos por 0, preservando a estrutura heteroscedástica sem introduzir distorções de calendário.

3.5 Estatísticas Descritivas (Tabela 4)

Para cada série (IIA-INFRA e quatro benchmarks), são calculadas as seguintes métricas sobre os retornos multiplicados por 100 (%):

- N — número de observações
- Média e Mediana
- Desvio Padrão (DP)
- Assimetria (Skewness) e Curtose Excessiva (ExKurt = kurtosis − 3)
- Mínimo e Máximo
- p-valor do teste de Jarque-Bera (normalidade)

3.6 Testes de Raiz Unitária (Tabela 5)

Implementados via pacote urca, para cada série e cada especificação:

Teste	Especificações	Critério de Lag	Hipótese Nula
ADF (Dickey-Fuller Aumentado)	drift, trend, none	BIC (selectlags)	Série possui raiz unitária
Phillips-Perron (Z-tau)	constant	short (lags automáticos)	Série possui raiz unitária

A decisão de rejeição é tomada ao nível de 5%: a estatística de teste é comparada ao valor crítico correspondente, e o resultado é registrado como "Sim" ou "Não" na coluna Rejeita_H0.

3.7 Teste KPSS de Estacionariedade (Tabela 6)

Complementar aos testes ADF/PP (cuja H0 é raiz unitária), o KPSS tem como hipótese nula a estacionariedade da série. Duas especificações são testadas:

- mu — estacionariedade em torno de nível constante
- tau — estacionariedade em torno de tendência determinística

A rejeição da H0 (Rejeita_H0 = "Sim") indica evidência contra estacionariedade ao nível de 5%.

3.8 Quebras Estruturais — Bai e Perron (Tabela 7)

Aplicado sobre o quadrado dos retornos (x^2) como proxy para a variância condicional. A função breakpoints() do pacote strucchange estima até 5 quebras ótimas com segmento mínimo de 15% da amostra (h = 0.15).

O número ótimo de quebras é determinado via breakpoints(bp), que minimiza o critério BIC. As datas das quebras detectadas são armazenadas em break_dates_map e usadas posteriormente para construir dummies na especificação da equação de média dos modelos GARCH.

3.9 Estimação de Memória Longa — GSEM / Robinson 1995 (Tabela 8)

Implementação da função gsem() — Gaussian Semiparametric Estimator — baseada no estimador de Robinson (1995). O parâmetro de integração fracionária d é estimado via minimização de um funcional do periodograma de Fourier.

São utilizadas três bandas de frequências m = floor(n^0.5), floor(n^0.6) e floor(n^0.7), fornecendo análise de robustez. O intervalo de confiança de 95% é calculado como $d \pm 1.96 \times (1 / 2\sqrt{m})$. A conclusão classifica a série em:

- Long memory (d > 0): IC inferior > 0
- Anti-persistence: IC superior < 0

- H0 not rejected: IC contém zero

3.10 Modelos ARMA(1,1)-FIGARCH(1,d,1) (Tabelas 9, 9B e 10)

O modelo mais sofisticado do pipeline. Para cada série:

Componente	Especificação	Justificativa
Equação de Média	ARMA(1,1) + dummies de quebra + intercepto	Captura autocorrelação e efeitos de regime
Equação de Variância	FIGARCH(1,d,1)	Memória longa na volatilidade
Distribuição dos Erros	t-Student	Leptocurtose empírica dos retornos financeiros
Solver	hybrid (BFGS + Nelder-Mead)	Robustez à não-convergência
Fallback	sGARCH(1,1)	Caso FIGARCH não convirja

Os diagnósticos de resíduos (Tabela 10) incluem:

- Ljung-Box sobre resíduos padronizados z (20 lags) — testa autocorrelação residual
- Ljung-Box sobre z^2 (20 lags) — testa heteroscedasticidade residual
- ARCH-LM (FinTS::ArchTest, 10 lags) — teste formal de efeitos ARCH remanescentes

O modelo é classificado como "Adequate" se ambos os p-valores (LB e ARCH-LM) superam 5%.

3.11 Correlações de Pearson (Tabela 11)

Calculadas sobre a matriz de resíduos padronizados de todos os modelos ajustados. São apresentadas: (a) a matriz de correlação completa entre todas as séries, e (b) as correlações par-a-par do IIA-INFRA com cada benchmark individualmente.

O uso de resíduos padronizados (ao invés dos retornos brutos) remove os efeitos de média e volatilidade condicional, revelando dependências estruturais entre os ativos.

3.12 Backtesting de VaR (Tabela 12)

Realizado para o período a partir de 2024-01-01, nos níveis de confiança de 95% e 99%. A fórmula do VaR condicional é:

$$VaR_t = -(\mu_t + \sigma_t \cdot q_p(t\text{-}Student(\nu)))$$

onde μ_t e σ_t são extraídos diretamente do modelo GARCH ajustado e ν é o parâmetro de forma da t-Student estimado.

Dois testes são aplicados sobre os indicadores de violação $I_t = 1\{r_t < -|VaR_t|\}$:

Teste	H0	Estatística	Graus de Liberdade
Kupiec (1995)	Cobertura incondicional correta	LR razão de verossimilhança	1
Christoffersen (1998)	Independência temporal das violações	LR baseado em transições 0→0, 0→1, 1→0, 1→1	1

A conclusão final combina ambos os testes, classificando o modelo como "Adequate", "Rejects Coverage", "Rejects Independence" ou "Inconclusive".

3.13 Exportação para Excel

Todas as 11 tabelas de resultados são exportadas para um único arquivo Excel com múltiplas abas via writexl::write_xlsx(). O arquivo de saída é Resultados_V6_MASTER.xlsx, gravado no diretório de trabalho.

Aba	Conteúdo
Tab2_Liquidez	Métricas de liquidez dos FI-Infra selecionados
Tab4_Descritivas	Estatísticas descritivas dos retornos log (%)
Tab5_ADF_PP	Testes de raiz unitária ADF e Phillips-Perron
Tab6_KPSS	Teste de estacionariedade KPSS
Tab7_Bai_Perron	Datas e número de quebras estruturais
Tab8_GSEM	Estimativa do parâmetro d de memória longa
Tab9_Modelos	Especificação dos modelos por série
Tab9b_Coefs_GARCH	Coeficientes estimados com erros padrão e p-valores
Tab10_Diagnostico	Diagnóstico de resíduos (LB e ARCH-LM)
Tab11_Correlacao	Correlações de Pearson (resíduos padronizados)
Tab12_Backtesting	Backtesting de VaR — Kupiec e Christoffersen

4. Decisões Metodológicas Relevantes

4.1 Ausência de Ajuste de Calendário

O script adota deliberadamente retornos log diários crus, sem remoção de efeitos de calendário (sazonalidade de dia da semana, feriados etc.). Esta decisão preserva a estrutura heteroscedástica natural dos retornos financeiros, que seria distorcida por filtros de pré-processamento.

4.2 LOCF para Dados de Preço

O preenchimento de preços via Last Observation Carried Forward (na.locf()) é aplicado ao painel de preços antes do cálculo de retornos. Isso simula o comportamento real de um ativo que permanece estável no último preço negociado em dias sem negociação, sem introduzir valores artificialmente interpolados.

4.3 Dummies de Quebra Estrutural na Equação de Média

As datas de quebra identificadas pelo teste de Bai-Perron são incorporadas como variáveis dummy na equação de média do modelo ARMA-FIGARCH. Isso evita que descontinuidades no nível da série contaminem a estimação dos parâmetros GARCH.

4.4 Backtesting sobre Retornos Empíricos

O VaR é testado contra os retornos observados reais (não reconstruídos a partir do modelo), garantindo que o backtesting avalie a performance preditiva do modelo e não sua capacidade de replicar o passado.

4.5 Fallback sGARCH

Dado que a convergência do FIGARCH não é garantida para todas as séries, o script implementa um mecanismo de fallback automático para o modelo sGARCH(1,1). A especificação utilizada (FIGARCH ou GARCH) é registrada na Tabela 9 para transparência.

5. Fluxo de Execução e Saídas

5.1 Ordem de Execução

Passo	Ação	Saída no Console
1	Instalação e carregamento de pacotes	Silencioso (quietly = TRUE)
2	Download dos 36 tickers FI-Infra	"OK: TICKER" ou "ERROR: TICKER" por ativo
3	Download IBOV e leitura arquivos locais	"Data collection complete."
4	Cálculo de métricas de liquidez	"Computing liquidity metrics..."
5	Construção do IIA-INFRA	Pesos finais após cap de 15%; N de observações
6	Alinhamento de calendário	Período e N total de observações alinhadas
7–8	Estatísticas e testes de raiz unitária	Tabelas 4 e 5 formatadas
9	KPSS	Tabela 6
10	Bai-Perron	Tabela 7 com datas de quebra
11	GSEM	Tabela 8 com estimativas de d
12	ARMA-FIGARCH	Modelo usado por série; Tabelas 9, 9B, 10
13	Correlações e Backtesting	Tabelas 11A, 11B, 12
14	Exportação Excel	"Exporting results..." + mensagem de sucesso

5.2 Arquivo de Saída

O único arquivo gerado é ResultadosR.xlsx, no diretório de trabalho do R. Não há saídas intermediárias em disco — todos os objetos são mantidos em memória durante a sessão.

6. Tratamento de Erros e Robustez

O script adota uma estratégia defensiva em todos os pontos críticos:

Situação	Mecanismo	Comportamento
Ticker indisponível no Yahoo Finance	tryCatch() no loop de getSymbols()	Registra "ERROR: TICKER" e continua
Volume ou preço ajustado ausente	tryCatch() em calc_adtv() / calc_freq()	Retorna NA; ativo excluído pelos filtros
FIGARCH não converge	tryCatch() com fallback para sGARCH(1,1)	Usa sGARCH e registra "GARCH [Fallback]"
Bai-Perron sem quebras	Verificação is.na(bp_opt$breakpoints)	Registra N_Quebras = 0 e Datas = "None"
GSEM com erro numérico	tryCatch() nas três bandas de m	Registra NULL e pula a banda afetada
VaR com ph = 0 ou ph = 1	Verificação condicional antes do LR	Registra Kupiec_pval = NA
Christoffersen com pi = 0 ou 1	Verificação de limites em christoffersen_ind()	Retorna lr_ind = NA, pval_ind = NA

7. Referências Metodológicas

Referência	Aplicação no Script
Bai, J. & Perron, P. (2003). Computation and Analysis of Multiple Structural Change Models. Journal of Applied Econometrics.	Seção 3.8 — breakpoints() do pacote strucchange
Robinson, P.M. (1995). Gaussian Semiparametric Estimation of Long Range Dependence. Annals of Statistics.	Seção 3.9 — função gsem() implementada manualmente
Kupiec, P. (1995). Techniques for Verifying the Accuracy of Risk Measurement Models. Journal of Derivatives.	Seção 3.12 — teste LR de cobertura incondicional
Christoffersen, P. (1998). Evaluating Interval Forecasts. International Economic Review.	Seção 3.12 — teste de independência das violações
Baillie, R.T., Bollerslev, T. & Mikkelsen, H.O. (1996). Fractionally Integrated Generalized Autoregressive Conditional Heteroskedasticity. Journal of Econometrics.	Base teórica dos modelos FIGARCH — seção 3.10